

CIÊNCIA DE DADOS

Dataset Card

1. INTRODUÇÃO

Este **Dataset Card** documenta a base de dados cinema_orcamento_recepcao, desenvolvida no Trabalho 1 sobre Aquisição de Dados. A base foi construída a partir da integração de três fontes heterogêneas (**TMDB**, **OMDb** e **Letterboxd**) reunindo informações sobre orçamento de produção, bilheteria e diferentes aspectos da recepção crítica e popular de aproximadamente 1.000 filmes.

O dataset foi desenvolvido com o objetivo de possibilitar a análise da relação entre o investimento realizado na produção de um filme e seu desempenho perante o público. Busca-se investigar se maiores investimentos estão associados a melhores resultados financeiros e maior reconhecimento, ou se o retorno de um filme pode seguir uma dinâmica independente de sua recepção crítica e popular.

Nas seções seguintes, são apresentados os principais aspectos relacionados à construção da base, incluindo sua proveniência, processo de aquisição e integração dos dados, dicionário de variáveis, tratamento das informações e limitações éticas e metodológicas. Dessa forma, o documento busca garantir a transparência do processo na construção do dataset, além de fornecer o contexto necessário para a interpretação adequada dos dados e dos resultados obtidos a partir deles.

A.1 IDENTIFICAÇÃO

Nome da base: cinema_orcamento_recepcao

Grupo / integrantes:

Nome	N° de Matrícula
Karen Juliana Báez González	22551695
Lucas Eduardo Siqueira dos Santos	22251137

Luna Veiga Horta Braga	22551154
Samuel Davi Silva de Lima Chagas	22352935

Tema e Pergunta Motivadora:

- O tema da base é a relação entre o orçamento dos filmes e sua recepção pelo público e pela crítica.
- A pergunta que guia a análise é: Existe correlação positiva entre alto orçamento e aclamação (público/crítica), ou grandes investimentos impactam sobretudo a bilheteria?

Data da coleta: Os dados foram coletados entre os dias 12/09/2026 e 13/09/2026. A integração das três fontes foi realizada no dia 13/09/2026.

A.2 FONTES E PROVENIÊNCIA

Fonte 1 - TMDB (The Movie Database)

Nome e URL	TMDB https://www.themoviedb.org API https://api.themoviedb.org/3
Método	API REST, em duas etapas: Primeiro, uma busca de filmes ordenada por faturamento decrescente (GET /discover/movie, sort_by=revenue.desc, include_adult=false), percorrendo as páginas 1 a 50 (~1000 IDs). Depois, uma chamada por filme (GET /movie/{id}) para obter detalhes financeiros e o imdb_id. Pausa de ~0,25s entre requisições; chave de API armazenada em variável de ambiente (TMDB_API_KEY). Dados brutos salvos em dados_brutos/tmdb_raw.csv.
Licença / termos	O uso segue os Termos de Uso da API do TMDB, que exigem atribuição à plataforma. A coleta foi feita com uma chave de acesso pessoal, para fins exclusivamente acadêmicos.

Fonte 2 — OMDb (Open Movie Database)

Nome e URL	OMDb https://www.omdbapi.com
Método	API REST. Para cada imdb_id obtido na etapa do TMDb, foi feita uma chamada à API da OMDb (GET /?i={imdb_id}&apikey=...) para extrair a nota do IMDb (imdbRating), o número de votos (imdbVotes) e o Metascore. Foi utilizado o plano gratuito da API, com limite de aproximadamente 1000 requisições por dia. Dados brutos salvos em dados_brutos/omdb_raw.csv. Essa fonte substitui o scraping HTML do IMDb, que foi bloqueado por robots.txt (seção A.6).
Licença / termos	Plano gratuito para uso pessoal/educacional com chave. Redistribuição comercial sujeita aos termos do provedor.

Fonte 3 — Letterboxd

Nome e URL	Letterboxd https://letterboxd.com
Método	Web scraping HTML. Cada página foi acessada pela URL no padrão https://letterboxd.com/tmdb/{tmdb_id}/ , e a nota agregada foi extraída via parse do JSON-LD (aggregateRating), com fallback para a meta tag twitter:data2 quando necessário. Foi usado um User-Agent acadêmico identificável e pausa de 2 segundos entre requisições, com checkpoints a cada 50 filmes coletados. Dados brutos salvos em dados_brutos/letterboxd_raw.csv.
Licença / termos	Dados públicos de páginas de filme: coleta pontual para fins acadêmicos, respeitando rate limit e robots.txt (seção A.6). A redistribuição massiva dos

	dados do Letterboxd pode conflitar com os termos do site, uso restrito ao contexto da disciplina.
--	---

Chave de integração: A base utiliza o TMDb como fonte âncora, identificada pelo campo `tmdb_id`. A integração ocorre em duas etapas: primeiro, é realizado um left join entre TMDb e OMDb utilizando `imdb_id`; em seguida, o resultado é integrado ao Letterboxd por meio do `tmdb_id`. Não é realizado casamento por título, a fim de evitar ambiguidades decorrentes de diferenças de acentuação, capitalização ou grafia entre as fontes.

Todo o processo de coleta é registrado no log de proveniência `docs/proveniencia.jsonl`, que armazena o timestamp, a fonte, a URL utilizada com as chaves de API ocultadas, o método de coleta, o status HTTP e observações relevantes.

A.3 DICIONÁRIO DE VARIÁVEIS

Esta seção apresenta o dicionário de variáveis da base tratada, com seus respectivos tipos, descrições e unidades. As variáveis incluem informações dos filmes, avaliações das diferentes fontes e campos de controle da coleta.

Variável	Tipo	Descrição	Unidade
<code>tmdb_id</code>	numérica discreta	Identificador do filme no TMDb	id
<code>imdb_id</code>	texto	Identificador IMDb (tt...); pode estar ausente	id
<code>title</code>	texto	Título (TMDb)	—
<code>release_date</code>	data/hora	Data de lançamento	data
<code>budget</code>	numérica contínua	Orçamento de produção (0 na TMDb tratado como ausente)	USD
<code>revenue</code>	numérica contínua	Faturamento reportado na	USD

		TMDB	
genres	categórica (texto)	Gêneros concatenados com	—
runtime	numérica discreta	Duração	minutos
original_language	categórica	Código de idioma original (ISO 639-1)	—
tmdb_vote_average	numérica contínua	Nota média TMDB	escala ~0–10
tmdb_vote_count	numérica discreta	Número de votos TMDB	votos
imdb_rating	numérica contínua	Nota IMDb via OMDb	escala 0–10
imdb_votes	numérica discreta	Contagem de votos IMDb via OMDb	votos
metascore	numérica contínua	Metascore (crítica agregada) via OMDb	escala 0–100
letterboxd_rating	numérica contínua	Nota média Letterboxd	escala ~0–5
letterboxd_rating_count	numérica discreta	Contagem de ratings Letterboxd	votos
letterboxd_title	texto	Título na página Letterboxd	—
matched_omdb	booleana	True se houve match no join OMDb	—
matched_letterboxd	booleana	True se houve match no join Letterboxd	—
omdb_response	booleana	Flag de sucesso da resposta OMDb	—
omdb_error	texto	Mensagem de erro OMDb, se houver	—

url_final	texto	URL final após redirect no Letterboxd	URL
http_status	numérica discreta	Status HTTP da página Letterboxd	código HTTP

A.4 VOLUME E GRANULARIDADE

Linhas / colunas: A base tratada final possui 1000 linhas e 23 colunas.

O que representa uma linha: Cada linha representa um filme, identificado pelo campo tmdb_id.

Cobertura: A base é composta por uma amostra de aproximadamente 1.000 filmes com maior faturamento (revenue) no TMDb, obtida a partir da ordenação decrescente por faturamento e da coleta das páginas 1 a 50, sem aplicação de filtros geográficos. As datas de lançamento dos filmes presentes na base variam de 1939 a 2026. Importante destacar que não se trata de uma amostra aleatória do catálogo de filmes, e sim de um recorte voltado aos maiores sucessos de bilheteria.

Cobertura dos Joins (após limpeza)

Métrica	Valor
Match OMDb (matched_omdb)	991 / 1000
Match Letterboxd	1000/1000
Com imdb_rating	987
Com metacore	945
Com letterboxd_rating	989
budget ausente (incl. zeros convertidos)	34
revenue ausente	0

A.5 LIMITAÇÕES E DECISÕES

Dados descartados:

- Nenhum filme da lista TMDb foi removido na integração (left joins).
- Scraping HTML do IMDb não foi realizado (proibido por robots.txt/termos); notas IMDb/Metascore vêm da OMDb.
- Duplicatas por tmdb_id: 0 removidas (não havia).

Lacunas conhecidas:

- 9 filmes TMDb sem imdb_id → sem OMDb.
- Alguns imdb_id com resposta OMDb sem rating/Metascore.
- 11 filmes Letterboxd sem letterboxd_rating (página OK, mas sem aggregate no HTML).
- Viés de seleção: só blockbusters por bilheteria (revenue.desc) — pouco contraste com filmes de baixo orçamento; limita a pergunta motivadora.
- Orçamento/faturamento TMDb podem estar incompletos ou desatualizados; Letterboxd usa escala distinta (≈0–5) da IMDb/TMDb (≈0–10).

Decisões de limpeza relevantes:

- Tipos: datas → datetime; ratings/orçamento → numérico; imdb_votes sem vírgulas de milhar.
- budget == 0 ou revenue == 0 → ausente (NA), pois zero na TMDb costuma significar "não informado".
- Deduplicação por tmdb_id (keep first).
- Brutos em dados_brutos/ inalterados; limpeza só em dados_tratados/.

A.6 CONSIDERAÇÕES ÉTICAS

Contém dados pessoais? Não. Metadados e agregados públicos sobre filmes (notas médias, contagens). Não há CPF, e-mail, nomes de usuários individuais etc. Em relação à LGPD, o tratamento de dados pessoais não se aplica a esta base no sentido de titulares identificáveis.

Restrições de uso / redistribuição: Uso acadêmico na disciplina. Respeitar termos do TMDb, OMDb e Letterboxd; não republicar como produto comercial nem sobrecarregar os serviços. As chaves de API não entram no repositório (.gitignore + .env.example).

robots.txt verificado? Sim. Detalhes em docs/robots_verificacao.md: IMDb (User-agent: * → Disallow: /) → sem scrape HTML; Letterboxd permite /tmdb/{id}/ com rate limit.